

Créé par le Centre d'Excellence Cyberdéfense Aérospatiale (CEC)

Guide des tests **WAC (Windows Artefacts Collector)**

Logiciel de prélèvement d'artefacts Windows
pour l'investigation numérique



ARTEFACTS
SYSTÈME



FICHIERS
UTILISATEUR



PREUVES
NUMÉRIQUES

UN OUTIL AU SERVICE
DE L'INVESTIGATION
NUMÉRIQUE

WAC — Windows Artefacts Collector

[Guide des tests](#)

Version du logiciel	1.3.1
Édition du document	septembre 2026
Éditeur	Centre d'Excellence Cyberdéfense Aérospatiale (CEC) École de l'air et de l'espace, base aérienne 701, Salon-de-Provence

Ce document explique comment lancer à la main chacun des tests de WAC, ce que chacun prouve et ne prouve pas, et comment lire un échec. Il s'adresse à qui modifie le code ou veut vérifier une version avant de l'employer. Les durées et volumes cités ont été relevés sur la machine virtuelle de test et sur une collecte réelle; ce sont des ordres de grandeur. Le bilan de ces tests, et ce qu'ils garantissent, est dans le *Dossier de validation*.

Table des matières

1 Principes	2
1.1 Ce qu'un test de WAC doit prouver	2
1.2 Trois règles	2
2 Préparer l'environnement	3
2.1 Le poste Linux	3
2.2 Construire WAC et les harnais	3
2.3 La machine virtuelle de test	4
3 Le cycle de test dans la machine virtuelle	5
3.1 Lancer un cycle	5
3.2 Contrôler les sorties	5
3.3 Comparer deux passages	7
4 Les harnais de format	8
4.1 Empreintes : sha_test	8
4.2 Lecture JSON : json_test	8
4.3 Décompression : lznt1_test et xpress_test	8
4.4 Décompression LZX : lzx_test	9
4.5 Messages d'événements : wevt_test et event_messages_test	9
4.6 Journaux : evt_x_test	9
4.7 Lecteur de ruches : offline_registry_test	10
4.8 Conversions : system_conversions_test	10
4.9 Consigne : consigne_test	11
4.10 Lecture brute : raw_hive_test	11
4.11 Enregistrements NTFS : ntfs_fixup_test	11
4.12 Signatures : authenticode_test	12
4.13 Chaînes tierces : third_party_chain_test	12
4.14 Listes de confiance : inflate_test, cab_test, zip_test, csv_reader_test, trust_list_test	12

5 Les harnais de robustesse	14
5.1 Le principe	14
5.2 Raccourcis : lnk_test	14
5.3 Listes de sauts et Prefetch : parsers_test	14
5.4 Référence	15
6 Recouper sur une collecte réelle	16
7 Lire un échec	17
7.1 Codes de sortie	17
7.2 Localiser une lecture hors tampon	17
7.3 Une boucle sans fin	18

Principes

1.1 Ce qu'un test de WAC doit prouver

WAC produit des fichiers JSON. Qu'ils soient valides ne prouve presque rien : un champ lu au mauvais décalage, une date interprétée dans le mauvais fuseau, un nom décodé dans la mauvaise page de code donnent un JSON parfaitement valide — et faux. Les défauts les plus coûteux relevés dans WAC étaient tous de cette sorte : ils ne se voyaient qu'en confrontant une valeur à une autre source.

Les tests se rangent donc en trois familles, qui ne répondent pas à la même question :

Le cycle dans la machine virtuelle (chapitre 3) : WAC s'exécute-t-il jusqu'au bout sur un vrai Windows, et ses sorties sont-elles cohérentes entre elles ? Les *contrôles croisés* confrontent une valeur calculée par WAC à une valeur indépendante de la même collecte.

Les harnais de format (chapitre 4) : un décodeur donne-t-il exactement le résultat de la référence — l'outil de Microsoft, une norme publiée, une autre implémentation ?

Les harnais de robustesse (chapitre 5) : un analyseur lit-il en dehors de son tampon, ou boucle-t-il sans fin, sur un fichier tronqué ou forgé ?

1.2 Trois règles

1. **Un correctif s'accompagne du test qui aurait pris le défaut.** Et ce test se vérifie dans les deux sens : il passe sur la sortie corrigée, et il échoue quand on rejoue le défaut.
2. **Après tout changement, comparer au passage précédent,** et pas seulement lire les pastilles vertes : un artefact passé de 1 522 entrées à 573 n'allume aucun voyant (section 3.3).
3. **Une donnée réelle ne quitte pas le poste de test.** Une collecte réelle contient des données personnelles : elle se traite en local, ses copies temporaires s'effacent après usage, et rien n'en entre dans le dépôt (`vmtest/results/` est ignoré par git).

Préparer l'environnement

2.1 Le poste Linux

Tout se construit sur Linux, par compilation croisée MinGW-w64; les harnais tournent soit nativement, soit sous wine, soit dans la machine virtuelle.

```
sudo apt install g++-mingw-w64-x86-64 wine64 python3 python3-pip
pip install olefile          # lecteur OLE indépendant, pour les recoupements
```

2.2 Construire WAC et les harnais

```
./build-windows.sh --test
```

Produit, dans build-windows/	Rôle
WAC.exe	l'outil de collecte
raw_hive_test.exe	lecteur NTFS brut, utilisé par le cycle VM
tests/lnk_test.exe	robustesse de l'analyseur de raccourcis
tests/parsers_test.exe	robustesse des listes de sauts et des Prefetch
tests/evtx_test.exe, consigne_test.exe	décodeur de journaux, consigne (chapitre 4)
tests/offline_registry_test.exe	lecteur de ruches confronté à celui de Microsoft
tests/system_conversions_test.exe	conversions de WAC confrontées à celles de Windows
tests/ntfs_fixup_test.exe	vérification des enregistrements NTFS (enregistrements déchirés)

Attention

Les harnais sont volontairement dans build-windows/tests/, à l'écart de WAC.exe : ce sont des outils de test, qui n'ont rien à faire sur un support de collecte. Ne jamais y copier le dossier tests/.

La compilation doit se terminer sans aucun avertissement : les options -Wall -Wextra sont actives, et un avertissement a déjà signalé de vrais défauts.

Les autres harnais (chapitre 4) se construisent chacun par une commande donnée dans son en-tête et reprise dans ce guide ; plusieurs compilent nativement sous Linux.

2.3 La machine virtuelle de test

La VM est un Windows 11 piloté par le *qemu-guest-agent* : aucune interaction, aucun réseau, les commandes s'exécutent en NT AUTHORITY\SYSTEM. Sa création et ses prérequis sont décrits dans `vmtest/README_FR.md` ; en résumé :

```
cd vmtest
ISO_WIN=~/Téléchargements/Win11_25H2_French_x64_v2.iso ./create-vm.sh # une fois
python3 qga.py ping # l'agent répond ?
python3 qga.py run --shell "dir C:\\\" # exécuter une commande
python3 qga.py write <hôte> <invité> # envoyer un fichier
python3 qga.py read <invité> <hôte> # rapatrier un fichier
```

À retenir

Une commande lancée par `qga.py run` est coupée au bout de 30 minutes. Pour un test plus long (par exemple les Prefetch d'une machine réelle, section 5.3), le lancer en tâche détachée dans la VM et suivre son journal.

Le cycle de test dans la machine virtuelle

3.1 Lancer un cycle

```
cd vmtest
./run-wac-test.sh --build      # recompile, puis cycle complet
./run-wac-test.sh             # cycle complet avec les binaires déjà construits
./run-wac-test.sh --raw-only  # seulement la validation de la lecture brute
./run-wac-test.sh --no-split  # sans l'étape 7 (collecte puis conversion)
./run-wac-test.sh --binary-all # étape 7 avec --binary-all
```

Le cycle enchaîne : envoi de WAC.exe et raw_hive_test.exe dans la VM, validation de l'extraction brute d'une ruche (elle doit être refusée par reg load tant qu'elle n'est pas réparée, puis acceptée), exécution de WAC, puis rapatriement, dans le dossier vmtest/results/<horodatage>/, de :

- run.log — la sortie console de la collecte, qui se termine par END, Time elapsed quand WAC est allé au bout;
- raw.log — la trace du lecteur NTFS;
- les JSON des artefacts;
- exhibits/ — le manifeste de consigne, son sceau et la liste des fichiers réellement présents dans la consigne.

L'étape 7 sépare ensuite collecte et conversion (chapitre « Collecter ici, convertir ailleurs » de la documentation utilisateur) : --collect --events --binary, qui ne doit rien convertir; une conversion d'une consigne dont une pièce a été retouchée, qui doit être refusée avant toute lecture, avec sa raison; une conversion, dont les JSON passent les contrôles ci-dessous; une seconde conversion, dont les JSON doivent être identiques à la première, octet pour octet. Résultats dans split/ et split-again/.

3.2 Contrôler les sorties

```
python3 check-json.py results/<horodatage>
```

Chaque ligne commence par une coche verte (contrôle passé), une croix rouge (défaut) ou un signe « passer » (contrôle sans objet : l'artefact est absent ou vide). Le code de sortie vaut

0 si aucun contrôle n'a échoué. Au-delà de la validité JSON et de la forme des chemins, le script confronte des sources indépendantes :

Contrôle croisé	Ce qu'il a déjà trouvé
empreinte d'un Prefetch / suffixe de son nom de fichier	65 empreintes fausses sur 270 (hexadécimal sans remplissage)
nom de l'exécutable d'un Prefetch / début du nom de fichier	un nom lu 8 octets trop tôt (« \x11 » partout)
chemins \VOLUME{guid} d'un Prefetch résolus	20 066 chemins sur 20 066 non résolus
couples X / XUtc, listes comprises	double décalage horaire ; RunsUtc des Prefetch décalés de 2 h
décalage de chaque date locale / base tz	décalage du jour de collecte appliqué à toutes les dates ; dates de changement d'heure mal lues
aucune session antérieure au démarrage	décalages de dates, heure de démarrage en retard de 3,5 s
date ShimCache / date NTFS du manifeste	une date UTC traitée comme locale (-2 h)
entrées DestList / raccourcis des listes de sauts	les 15 premières entrées de chaque liste perdues
nom de machine des événements / OperatingSystem.json	contrôle du décodage BinXML
identifiants d'enregistrement uniques par journal	relecture d'un chunk périmé
montages / reg query et Get-Partition	chemins de périphérique publiés comme « \ »
précision des dates FAT et des dates lues en texte	sept chiffres de fraction sur des dates à la seconde
BAM, UserAssist, USBSTOR, Amcache / harnais, Prefetch, Windows, en-têtes PE	dates UTC lues comme locales (2 h)
noms des SID / Get-LocalUser, Get-LocalGroup	noms demandés au système, traduits (« Système »)
GUID enregistrés par le harnais (register-test-guids.ps1)	« Unmapped GUID » publié comme un nom
sceau / empreinte réelle du manifeste	retouche du manifeste
fichiers de la consigne / contenu du manifeste	209 pièces ajoutées après le scellement
SHA-256 de fichiers lus en brut / Get-FileHash	garde-fou de la lecture par lots de clusters

Contrôle croisé	Ce qu'il a déjà trouvé
dates des Prefetch / dates données par Windows	0 sur 335 conformes : dates de la copie de travail
exécutables de System32 et SysWOW64 / manifeste d'un --collect --binary	6 446 manquants sur 8 540 (\$INDEX_ROOT en enregistrement d'extension, liens physiques)
catalogues cités dans un verdict / pièces de la consigne	170 sur 170 absents (libellé « catalog » cherché comme « catalogue »)
verdicts Microsoft de WAC / Get-AuthenticodeSignature	garde-fou : un mauvais verdict laisserait un binaire hors de la consigne
copie d'un paquet du Store (intact, modifié, ajouté) / verdicts	vérification par la carte des blocs signée
deux conversions d'une même collecte	dates lues sur la copie de travail, refaite à chaque conversion
dates falsifiées d'un script / \$STANDARD_INFORMATION et \$FILE_NAME	garde-fou : la falsification doit rester visible
clés de récupération / en-têtes PE lus par PowerShell	garde-fou du contenu récupérable
--binary-all / copie et verdict de chaque exécutable	contrôle des paquets trop strict en --binary-all
verify-exhibits.ps1 / collecte séparée	pièces « empreinte seule » déclarées altérées

La liste complète, avec l'histoire de chaque contrôle, est dans `vmtest/README_FR.md`.

3.3 Comparer deux passages

Une pastille verte ne dit pas si une donnée a disparu. Après tout changement, comparer la nouvelle collecte à la précédente : nombre d'entrées de chaque artefact, et valeurs perdues ou gagnées. Deux précautions :

- une collecte change d'elle-même d'un passage à l'autre : horodatages, nouveaux événements, fichiers Prefetch mis à jour, empreinte de \$MFT. On compare donc les éléments *appariés* — par exemple un Prefetch par son empreinte de chemin et sa dernière exécution — en écartant les dates de la copie extraite;
- une valeur « perdue » peut n'être qu'un champ vide qui n'est plus émis, ou une clé renommée : normaliser avant de conclure.

CHAPITRE 4

Les harnais de format

Chacun confronte un décodeur de WAC à une référence. Tous sont exclus de la compilation de WAC par le suffixe `_test.cpp`.

4.1 Empreintes : sha_test

Confronte SHA-1 et SHA-256 aux vecteurs publiés de FIPS 180-4, et aux longueurs 55 à 128 octets, qui exercent le remplissage — le seul endroit où une implémentation par ailleurs juste se trompe.

```
cd WAC && g++ -std=c++17 -I. sha.cpp sha_test.cpp -o /tmp/sha_test && /tmp/sha_test
```

4.2 Lecture JSON : json_test

`--convert` relit ce que `--collect` a écrit : le manifeste des pièces et l'instantané de l'état en direct. Le harnais vérifie que tout ce que l'écrivain de WAC produit se relit à l'identique, que les fichiers d'une vraie collecte se relisent et se réécrivent à l'octet près, que les textes malformés sont refusés, et que 200 000 mutations aléatoires ne font jamais lire hors borne (AddressSanitizer, UBSan).

```
cd WAC && g++ -std=c++17 -g -fsanitize=address,undefined -I. json_test.cpp -o /tmp/  
    json_test  
/tmp/json_test ../vmtest/results/<horodatage>/*.json
```

4.3 Décompression : lznt1_test et xpress_test

Vérifient les décompresseurs NTFS (LZNT1) et WOF (XPRESS Huffman) contre le *compresseur de Microsoft* : un fichier connu est compressé dans la VM par `RtlCompressBuffer`, unité par unité, et le harnais décompresse chaque unité puis la compare octet pour octet à l'original. Un décompresseur faux décode le plus souvent sans erreur : seule la comparaison exhaustive le révèle.

```
cd WAC  
g++ -std=c++17 -I. lznt1.cpp lznt1_test.cpp -o /tmp/lznt1_test  
g++ -std=c++17 -I. xpress.cpp xpress_test.cpp -o /tmp/xpress_test  
/tmp/lznt1_test <original> <compressé.bin> <index.idx>  
/tmp/xpress_test <original> <compressé.bin> <index.idx>
```

index.idx porte une ligne <n> <taille originale> <taille compressée> par unité; une taille compressée nulle désigne une unité que Windows a renoncé à compresser.

4.4 Décompression LZX : lzx_test

Le quatrième algorithme de WOF, LZX sur des blocs de 32 Kio, n'est produit que sur demande. Les données de test viennent de Windows lui-même : dans la VM, compact /c /exe:lzx compresse un fichier, et raw_hive_test --wof en dépose le flux compressé tel qu'il est sur le disque. Le test décompresse chaque bloc et le compare à l'original, puis soumet chaque bloc tronqué et altéré au hasard (graine fixe) au décodeur, compilé avec AddressSanitizer et UBSan : aucune lecture ni écriture hors borne, et jamais une « réussite » de taille fausse.

```
cd WAC
g++ -std=c++17 -g -fsanitize=address,undefined -I. lzx.cpp lzx_test.cpp -o /tmp/lzx_test
/tmp/lzx_test <original> <flux-wof.bin>
```

Référence : ntoskrnl.exe, shell32.dll et un fichier texte, 646 blocs sur 646 identiques, 235 707 contrôles, aucun échec. Le cycle VM vérifie en outre, à chaque passage, le SHA-256 de ces trois fichiers compressés en LZX et lus en brut contre Get-FileHash.

4.5 Messages d'événements : wevt_test et event_messages_test

wevt_test vérifie la chaîne qui transforme un événement en phrase, sur les fichiers d'un vrai fournisseur : sa DLL et son satellite localisé.

```
cd WAC && g++ -std=c++17 -I. pe_resource.cpp wevt.cpp wevt_test.cpp -o /tmp/wevt_test
/tmp/wevt_test gpsvc.dll fr-FR/gpsvc.dll.mui "{ae1b4fa-97d1-45f2-a64c-4d69fffd92c9}" 1002
4001
```

event_messages_test fait de même à partir de la ruche SOFTWARE; il tourne sur la machine examinée ou dans la VM, seuls endroits où la ruche et les binaires des fournisseurs sont lisibles :

```
event_messages_test <ruche SOFTWARE> <guid> [id[:version] ...]
```

4.6 Journaux : evtx_test

Lit un .evtx hors de Windows, sous wine; construit par build-windows.sh --test, dans build-windows/tests/. Il sert à éprouver le décodeur sur des journaux que la VM ne produit pas : anciens, transférés, mal fermés, abîmés — et à comparer enregistrement par enregistrement à une implémentation indépendante (python-evtx).

```
wine evtx_test.exe "Z:/chemin/Security.evtx"          # bilan par journal
wine evtx_test.exe "Z:/chemin/Security.evtx" 3        # + XML de 3 enregistrements
wine evtx_test.exe "Z:/chemin/Security.evtx" --dump   # un enregistrement par ligne
```

```
wine evt_x_test.exe --collect "Z:/tmp/arbre" "Z:/tmp/sortie"          # chaine complete
wine evt_x_test.exe --collect-memory "Z:/tmp/arbre" "Z:/tmp/sortie2" # meme chaine, en
    memoire
cmp /tmp/sortie/events.json /tmp/sortie2/events.json                # doit etre muet
```

4.7 Lecteur de ruches : offline_registry_test

WAC lit les ruches du registre avec son propre lecteur (offline_registry.cpp), lié dans l'exécutable : il ne dépend plus de la bibliothèque offreg.dll de Microsoft, que Windows fournit et qu'il empruntait donc à la machine examinée. Ce harnais confronte les deux : il charge la DLL de Microsoft depuis le chemin donné, parcourt chaque ruche avec les deux lecteurs et compare chaque clé (nom, date, classe, compteurs, maxima, taille du descripteur de sécurité) et chaque valeur (nom, type, octets), ainsi que les cas limites du contrat : tampon trop petit, sondage de taille, valeur par défaut, clé ou valeur absente. Aucun écart n'est admis.

```
offline_registry_test.exe C:\Windows\System32\offreg.dll SYSTEM SOFTWARE SAM ntuser.dat
...
```

À lancer sous Windows (la VM), sur des ruches rejouées : celles de working/ d'une collecte. Seul écart voulu : une ruche dont les journaux n'ont pas été rejoués est refusée par WAC, alors que les versions récentes de la DLL de Microsoft la lisent telle quelle — des clés périmées, sans erreur; le harnais le signale comme attendu. Référence : 18 ruches, dont dix d'une machine réelle, soit 1 273 652 clés et 2 456 139 valeurs identiques.

4.8 Conversions : system_conversions_test

WAC n'importe que ce qu'exige l'interrogation du système en marche (ADVAPI32, KERNEL32, msvcrt, Secur32, WTSAPI32). Les conversions qu'il demandait à d'autres bibliothèques sont faites par son propre code; ce harnais les confronte aux fonctions Windows remplacées : GUID (StringFromGUID2), SID dans les deux sens (ConvertSidToStringSidW, ConvertStringSidToSidW), dates OLE (VariantTimeToSystemTime) et noms de propriétés (PSGetNameFromPropertyKey), dates FAT (DosDateTimeToFileTime, sur toutes les dates), et l'heure d'été : le décalage de WAC dans les deux sens (SystemTimeToTzSpecificLocalTimeEx, TzSpecificLocalTimeToSystemTimeEx) sur *tous* les fuseaux de Windows, avec leurs règles année par année, aux transitions (heure sautée, heure répétée, changement de règle au 1^{er} janvier) de 1980 à 2035; la lecture de SYSTEM\...\TimeZoneInformation, dont les dates de changement d'heure sont des TIME_FIELDS et non des SYSTEMTIME; des règles forgées au hasard; la relecture des dates ISO 8601 du manifeste (iso8601UtcToFiletime, exacte au 100 ns sur 200 000 instants, et refus des dates mal formées). Il vérifie aussi le décalage horaire du suspect dans les deux sens : une date locale convertie en UTC doit l'être avec le fuseau de la machine examinée, et non avec celui de la machine qui exécute WAC. Une date impossible (mois 13, heure 25) donne une date nulle, donc non émise. La table des noms de propriétés est générée depuis le schéma d'un Windows de référence par vmtest/property-schema.cpp.

```
system_conversions_test.exe
```

À lancer sous Windows (la VM). Référence : 9 861 570 comparaisons, aucun écart. Deux écarts voulus : WAC refuse un SID écrit que Windows tronquerait (sous-autorité de 2^{32} ou plus, seizième sous-autorité), et une date NaN, pour laquelle Windows rend une heure dénuée de sens.

4.9 Consigne : consigne_test

Rejoue la chaîne de production — empreintes, manifeste, copie vérifiée, rejeu des ruches — sur des ruches données en argument, et vérifie ce qu'aucune compilation ne révèle : la consigne reste identique octet pour octet pendant que la copie de travail est modifiée, et le sceau porte l'empreinte réelle du manifeste. Il vérifie enfin qu'un chemin de pièce lu dans un manifeste reste dans la consigne : un composant .. est refusé, un nom de WinSxS qui contient .. (i..sermode) est accepté.

```
cd build-windows/tests
wine consigne_test.exe "Z:/tmp/sortie" "Z:/chemin/SYSTEM" "Z:/chemin/ntuser.dat"
```

4.10 Lecture brute : raw_hive_test

Extrait un fichier en lisant directement le volume NTFS. À lancer sous Windows, en administrateur; le cycle VM l'utilise pour valider l'extraction d'une ruche.

```
raw_hive_test.exe [volume] [chemin] [sortie] [--fix] [--list] [--attrs]
```

--fix rend la ruche extraite chargeable, --list liste un répertoire, --attrs affiche les attributs \$MFT du fichier sans les interpréter.

4.11 Enregistrements NTFS : ntfs_fixup_test

NTFS écrit un enregistrement de la \$MFT ou un bloc d'index secteur par secteur, et termine chaque tranche de 512 octets par un numéro de séquence. WAC vérifie ce numéro avant de restituer les vrais octets : un enregistrement déchiré par une écriture interrompue est refusé. Le harnais construit des enregistrements dont le résultat attendu est connu (sains, déchirés dans chaque tranche, tableaux malformés), puis confronte le verdict de WAC à une vérification indépendante sur 20 000 enregistrements aléatoires placés contre une page interdite. Aucune donnée n'est nécessaire.

```
cd build-windows/tests && wine ntfs_fixup_test.exe
```

Référence : 44 610 contrôles, aucun échec. Sur un vrai volume, le cycle de la VM le confirme : raw.log ne doit contenir aucun « torn record ».

4.12 Signatures : `authenticode_test`

Vérifie les catalogues d'un dossier puis rend un verdict par fichier; ses verdicts se comparent à ceux de Get-AuthenticodeSignature sur les mêmes fichiers, dans la VM. Le seul écart qui compte : un fichier accepté par WAC et refusé par Windows.

```
authenticode_test --catalogs <dossier>
authenticode_test --catalogs <dossier> --files <liste>
```

4.13 Chaînes tierces : `third_party_chain_test`

Chaque règle de la vérification des chaînes tierces sur des chaînes fabriquées par openssl pour l'enfreindre (`third_party_chain_fixtures.sh`) : chaîne saine acceptée; racine absente, exclue de la signature de code, désapprouvée; clé d'autorité désapprouvée par Microsoft; autorité révoquée selon la CCADB; émetteur sans cA; signataire réservé au web; autorité du bon nom mais d'une autre clé; autorité ECDSA (non vérifiée). Chaque règle neutralisée tour à tour fait échouer le test (huit mutations). Les signatures réelles se recoupent par `authenticode_test --trust`, face à openssl `verify` avec le `roots.pem` du jeu (installateurs de Git, Notepad++, PuTTY, Python, VLC; jeu complet et jeu privé des racines Sectigo); dans la VM, aucune chaîne jugée de confiance par WAC ne l'est pas par Get-AuthenticodeSignature.

```
./third_party_chain_fixtures.sh /tmp/chain
/tmp/third_party_chain_test /tmp/chain
```

4.14 Listes de confiance : `inflate_test`, `cab_test`, `zip_test`, `csv_reader_test`, `trust_list_test`

`--update-trust` décompresse et lit ce que Microsoft publie; une erreur donnerait une sortie valide et fausse. Chaque maillon a donc sa référence indépendante, et se construit sous Linux avec AddressSanitizer et UBSan :

- `inflate_test` : DEFLATE, confronté à zlib sur 49 flux, puis flux tronqués et abîmés au hasard (graine fixe);
- `cab_test` : cabinets MSZIP, extraction identique octet pour octet à celle de cabextract sur les vrais `authrootstl.cab` et `disallowedcertstl.cab` (1 134 contrôles);
- `zip_test` : archives ZIP, extraction identique à celle de `zipfile` (Python) sur la vraie liste de pilotes vulnérables de Microsoft et deux archives synthétiques (stockée, compressée, commentaire, dossiers, fichier vide); une archive abîmée ne rend jamais un contenu altéré, refusé par son CRC-32 (1 717 contrôles);
- `csv_reader_test` : le rapport CSV de la CCADB, lu champ pour champ comme par le module `csv` de Python (10 284 enregistrements, empreinte SHA-256 de chaque champ), puis guillemets doublés, sauts de ligne dans un champ, CRLF, guillemet non fermé,

enregistrement incomplet;

- `trust_list_test` : les comptes de `authroot.stl` (racines pour la signature de code, pour l'horodatage, et pour la signature de code non désapprouvées), calculés à part par une lecture DER en Python; les certificats que bloque Chromium (`net/data/ssl/blocklist`), reconnus par `disallowedcert.stl`; une liste modifiée d'un octet, refusée; les deux listes lues par huit fils à la fois, cache des chaînes vide, comme les fils d'analyse de `--collect --binary`. Construit une seconde fois avec `-fsanitize=thread` (lancé par `setarch -R`, que ThreadSanitizer exige sur les noyaux récents), il signalait onze courses de données sur ce cache avant son verrou.

```
g++ -std=c++17 -g -fsanitize=address,undefined -I. authenticode.cpp rsa.cpp \
    sha.cpp quickdigest5.cpp trust_list_test.cpp -o /tmp/trust_list_test
/tmp/trust_list_test authroot.stl 313 335 145 disallowedcert.stl blocklist 36
```

Référence (listes du 25 août 2026 et du 5 septembre 2025) : 80 contrôles, aucun échec. C'est ce test qui a établi ce que contient `disallowedcert.stl`, que Microsoft ne documente pas : ses entrées de 16 octets sont le MD5 de la **clé publique** (et non de la partie signée, comme le nom de la propriété le laisse croire), celles de 48 octets le SHA-384 de la partie signée.

Le résultat de bout en bout se contrôle dans la VM : les 562 racines écrites par `--update-trust` sont identiques, octet pour octet, à celles que produit `certutil -generateSSTFromWU`. Les listes de pilotes vulnérables se recoupent par une lecture Python du XML et du JSON téléchargés : mêmes 1 086 empreintes Microsoft, 217 signataires refusés, 8 151 empreintes LOLDrivers. Les CRL se contrôlent par `openssl` : chacune se lit, et son émetteur est l'autorité que lui associe la CCADB (387 sur 387).

Les harnais de robustesse

5.1 Le principe

Un analyseur lit à des positions que le fichier lui-même déclare. Sur un fichier tronqué ou forgé, une lecture au-delà du tampon ne plante pas d'elle-même : elle lit la mémoire voisine et la publie, dans un JSON valide. Les harnais la font planter : chaque entrée est copiée contre une page mémoire interdite (PAGE_NOACCESS), une fois *finissant* contre elle (lectures au-delà de la fin), une fois *commençant* juste après elle (lectures en deçà du début, par exemple à une position négative tirée de la donnée). Un seul octet lu hors de l'entrée provoque une violation d'accès.

Pour chaque fichier donné, le harnais analyse :

- le fichier entier;
- ses troncatures (toutes les longueurs pour les petits fichiers);
- des copies dont des octets ont été remplacés au hasard, avec une graine fixe : un échec se reproduit à l'identique.

5.2 Raccourcis : lnk_test

```
cd build-windows/tests
wine lnk_test.exe a.lnk b.lnk ...
```

Sources de fichiers : le dossier Recent et le menu Démarrer de la VM, ou ceux d'une collecte (Users\<nom>\AppData\Roaming\Microsoft\Windows\Recent). Les noms accentués ou non latins passent mal dans la ligne de commande de wine : copier les fichiers sous des noms numérotés.

5.3 Listes de sauts et Prefetch : parsers_test

```
parsers_test.exe jumplist-auto <fichier.automaticDestinations-ms> ...
parsers_test.exe jumplist-custom <fichier.customDestinations-ms> ...
parsers_test.exe prefetch <fichier.pf> ...
parsers_test.exe hive <ruche> ...
```

Le type hive éprouve le lecteur de ruches : chaque entrée est ouverte depuis la mémoire, contre la page interdite, et toute l'arborescence est parcourue (sous-clés, valeurs,

ORQueryInfoKey). Une sous-clé qui pointerait vers l'une de ses ancêtres est refusée par le lecteur : sans cela, un parcours récursif ne finirait jamais.

Les listes de sauts se testent sous wine, comme lnk_test. Les Prefetch se testent **dans la VM** : ils sont compressés (XPRESS Huffman), et seule la bibliothèque ntdll de Windows les décompresse. Le harnais décompresse chaque fichier avant de l'éprouver : c'est l'analyseur de WAC qu'il vise, pas le décompresseur de Windows.

Pour les 307 Prefetch d'une machine réelle (plus d'un million d'entrées), il faut compter environ deux heures dans la VM : lancer le test en tâche détachée, par lots, et suivre son journal. Exemple de script PowerShell, déposé dans la VM avec qga.py write :

```
$files = Get-ChildItem C:\wactest\pt\pf\*.pf | ForEach-Object { $_.FullName }
$log = 'C:\wactest\pt\pf_results.txt'
for ($i = 0; $i -lt $files.Count; $i += 20) {
    $batch = $files[$i..([Math]::Min($i + 19, $files.Count - 1))]
    Add-Content $log (& C:\wactest\pt\parsers_test.exe prefetch @batch 2>&1)
    Add-Content $log ("batch " + $i + " exit=" + $LASTEXITCODE)
}
Add-Content $log 'DONE'
```

5.4 Référence

Résultats obtenus sur une machine réelle, chaque entrée analysée des deux côtés de la page interdite :

Fichiers	Entrées	Où
220 raccourcis	546 214	wine
48 listes de sauts automatiques	175 585	wine
23 listes de sauts personnalisées	79 036	wine
307 Prefetch	1 246 491	VM, environ 2 h
4 ruches du registre	16 207	wine

Recouper sur une collecte réelle

Une VM fraîchement installée ne produit ni fragmentation, ni listes de sauts anciennes, ni noms de fichiers exotiques. Plusieurs défauts ne se sont révélés que sur une collecte réelle, confrontée à une source indépendante :

- **listes de sauts / olefile** : les flux et le DestList, relus par un lecteur OLE indépendant, doivent donner exactement les mêmes entrées (numéros, dates, chemins). C'est ce qui a montré que les flux s'appellent « 1 » à « f » et non « 01 » à « 0f »;
- **raccourci / DestList** : dans une liste de sauts, la cible d'un raccourci et le chemin de son entrée DestList sont deux enregistrements du même fichier. Leur désaccord a révélé une page de code fausse (« d\x92orientation ») et un chemin Unicode ignoré;
- **événements / python-evtx** : comparaison enregistrement par enregistrement (evtx_test --dump);
- **signatures / Get-AuthenticodeSignature** (authenticode_test);
- **ancienne collecte / nouvelle** : décoder les mêmes fichiers avec le code courant et comparer, après normalisation, à la sortie d'une version précédente.

Attention

Une collecte réelle se traite en local. Si une ruche doit être confrontée au lecteur de Microsoft (offline_registry_test), elle peut être copiée dans la VM de test, puis effacée aussitôt le test fini. Aucune copie ne reste dans le dossier de travail temporaire, et rien n'en entre dans le dépôt.

Lire un échec

7.1 Codes de sortie

Code	Signification
0	tout est passé
1	échec d'un contrôle, ou fichier d'entrée illisible
2	mauvais usage (arguments)
3	parsers_test : une analyse ne s'est pas terminée en 60 s (chien de garde)
0xC0000005 (-1073741819)	violation d'accès : lecture hors du tampon

7.2 Localiser une lecture hors tampon

Sous wine, une faute affiche la pile d'appels, avec des adresses relatives au programme (lnk_test+0x485bb). Sous Windows, parsers_test affiche lui-même l'entrée en cause et l'adresse fautive :

```
FAILED exception 0xC0000005 at exe+0x78b70, address read 0x159deb4200c:  
C:\wactest\pt\pf\CMD.EXE-0BD30981.pf truncated at 192 (guard after)
```

L'adresse se traduit en fonction avec la table des symboles du programme (adresse de base 0x140000000) :

```
x86_64-w64-mingw32-nm -C parsers_test.exe | grep -i " t " | sort > syms.txt  
# chercher le symbole dont l'adresse est juste inférieure à 0x140000000 + 0x78b70  
x86_64-w64-mingw32-objdump -d --start-address=0x140078b40 \  
--stop-address=0x140078b80 parsers_test.exe
```

L'instruction désassemblée donne le décalage lu (ici 0xcc(%r14)); il se rapproche alors, dans le code source, du champ lu à cette position. Rejouer ensuite l'entrée exacte (la troncature ou la corruption indiquée) pour vérifier la correction, puis toute la série.

7.3 Une boucle sans fin

Si `parsers_test` s'arrête sur « no end after 60 s », l'entrée nommée fait tourner un analyseur sans fin — typiquement une chaîne de secteurs cyclique dans un conteneur OLE. C'est un défaut au même titre qu'une lecture hors tampon : un fichier forgé suffirait à bloquer une collecte.